UNIVERSIDAD COMPLUTENSE DE MADRID

Facultad de Estudios Estadísticos

Máster en Big Data, Data Science & Inteligencia Artificial

Clasificación binaria de churn con selección de variables y redes neuronales

Tarea de Tarea de minería de datos y modelización predictiva

Autor: Daniel Olmedo Rawlins Poveda

Profesor: Pablo Arcadio Flores

Curso académico: 2025–2026

Madrid, 19 de abril de 2026

Índice

1. Introducción **1**

1.1. Objetivo 1

2. Descripción del conjunto de datos **1**

2.1. Variables y objetivo 2

3. Análisis y depuración de datos **2**

3.1. Criterios de depuración 3

3.2. Feature engineering 4

4. Protocolo experimental **5**

4.1. Partición y validación 5

4.2. Validación de candidatas de feature engineering 5

4.3. Selección de umbral 6

4.4. Métricas 6

5. RFE con regresión logística y red neuronal optimizada en Accuracy **7**

5.1. Selección de variables con RFE 7

5.2. Ajuste del modelo y selección final 8

6. Árbol de decisión y red neuronal optimizada en Recall **9**

6.1. Selección inicial de variables con árbol 9

6.2. Optimización final del modelo de Recall 10

7. Comparación global **11**

7.1. Desempeño predictivo en test 11

7.1.1. Métricas finales 11

7.2. Trade-off entre objetivos 12

7.3. Sensibilidad de los guardrails para Recall 13

7.4. Interpretabilidad y complejidad 13

7.4.1. Variables seleccionadas 13
7.5. Utilidad práctica para churn 14
7.5.1. Escenario 1: Minimizar falsos positivos (retención proactiva) 14
7.5.2. Escenario 2: Máxima cobertura (no perder ningún churn) 15
7.6. Recomendación 15

8. Conclusiones **16**
8.1. Síntesis de hallazgos 16
8.1.1. Fase 1: Auditoría de datos 16
8.1.2. Fase 2: Selección de candidatas 16
8.1.3. Fase 3: Modelos finales 17
8.2. Limitaciones del estudio 17
8.2.1. Limitaciones técnicas 17
8.2.2. Limitaciones operativas 17
8.3. Conclusiones metodológicas 18
8.4. Conclusiones prácticas 18
8.5. Trabajo futuro 19
8.6. Reflexión final 19

A. Apéndice **20**

1. Introducción

La modelización predictiva es una herramienta clave para anticipar la ocurrencia de eventos binarios en contextos de toma de decisiones. En este marco, los modelos de *customer churn* (abandono de clientes) pueden interpretarse como un caso particular de modelos de puntuación de riesgo.

El problema de churn consiste en estimar la probabilidad de que un cliente abandone un servicio en un horizonte temporal determinado, lo que se formula como un problema de clasificación binaria.

En este trabajo se desarrolla un proceso completo de modelización predictiva, que incluye la depuración de datos, la selección de variables, la estimación de modelos y la evaluación de su capacidad predictiva.

Asimismo, se comparan distintos enfoques, desde modelos clásicos como la regresión logística hasta modelos más flexibles como árboles de decisión y redes neuronales.

1.1. Objetivo

El objetivo principal de este trabajo es desarrollar y comparar distintos modelos de clasificación para la predicción del churn, evaluando su rendimiento bajo un protocolo experimental reproducible. En particular, se pretende:

- Describir el problema de churn y su formulación como un problema de clasificación binaria.
- Implementar un proceso riguroso de preprocesamiento y selección de variables.
- Estimar distintos modelos predictivos, incluyendo regresión logística, redes neuronales y árboles de decisión.
- Comparar el desempeño de los modelos utilizando métricas adecuadas de evaluación.

Todo el análisis se realizará siguiendo criterios de reproducibilidad y consistencia metodológica, de manera que los resultados obtenidos puedan ser interpretados y replicados de forma transparente.

2. Descripción del conjunto de datos

El conjunto de datos utilizado en este trabajo corresponde a clientes de una empresa de telecomunicaciones y tiene como finalidad predecir el riesgo de abandono del servicio. La

base está formada por veinte variables explicativas, denotadas como $V1$ a $V20$, y una variable objetivo Y, que identifica si el cliente ha abandonado o no la compañía.

Desde un punto de vista conceptual, las variables disponibles recogen distintas dimensiones del comportamiento del cliente, incluyendo información territorial, características del contrato, uso del servicio y relación con la empresa. Esta estructura sugiere la posible existencia de variables identificadoras, variables categóricas codificadas numéricamente y relaciones de dependencia entre variables de uso y facturación.

2.1. Variables y objetivo

La variable objetivo del problema es Y, que toma valor 1 cuando el cliente abandona el servicio y valor 0 en caso contrario, configurando así un problema de clasificación binaria.

Las variables explicativas pueden agruparse en distintas categorías:

- **Identificación y localización**: $V1$ (estado o región), $V3$ (código de área) y $V4$ (número de teléfono). Estas variables pueden incluir información categórica o identificadora, siendo especialmente relevante el carácter no predictivo esperado de $V4$.
- **Características del cliente**: $V2$ (duración de la cuenta), que refleja la antigüedad del cliente en la compañía.
- **Servicios contratados**: $V5$ (plan internacional), $V6$ (plan de buzón de voz) y $V7$ (número de mensajes), que capturan el tipo de servicios activos.
- **Uso y facturación**: $V8$–$V19$, que recogen minutos, número de llamadas y costes asociados en distintos periodos (diurno, vespertino, nocturno e internacional). Estas variables presentan potenciales relaciones de dependencia, ya que los costes suelen derivarse directamente del uso.
- **Atención al cliente**: $V20$ (número de llamadas al servicio de atención), que puede actuar como indicador de insatisfacción o problemas con el servicio.

Esta clasificación inicial permite anticipar distintos tratamientos en la fase de preprocesamiento, especialmente en lo relativo a la codificación de variables categóricas, la eliminación de identificadores y la detección de posibles redundancias.

3. Análisis y depuración de datos

Esta sección documenta la ingesta y auditoría inicial del conjunto de datos, así como las decisiones de depuración adoptadas antes de cualquier partición entrenamiento–test. El

objetivo es garantizar trazabilidad metodológica, reducir sesgos evitables y preparar un conjunto de modelado coherente con el enunciado.

3.1. Criterios de depuración

El dataset contiene 9200 observaciones y 21 variables (20 predictoras y la variable objetivo binaria Y). Tras cargar los datos con interpretación explícita de `NA` como valor perdido, se observó la siguiente situación de calidad:

- **Valores perdidos**: se detectaron faltantes en $V3$, $V10$, $V14$, $V15$ y $V19$, con porcentajes bajos (todos por debajo del 1 %).
- **Distribución de la clase objetivo**: $Y = 0$ y $Y = 1$ presentan exactamente 4600 casos cada una (50 %–50 %).
- **Duplicados exactos**: se identificaron 5662 filas duplicadas exactas sobre 9200 registros.

Desde el punto de vista conceptual, se adoptó la clasificación inicial establecida en el protocolo del trabajo: $V1$ y $V3$ como variables nominales codificadas, $V5$ y $V6$ como binarias, $V4$ como candidata a identificador, y el bloque $V8$–$V19$ como variables de uso/coste.

Con base en estos resultados, se fijaron las siguientes decisiones metodológicas **antes del split**:

1. **Deduplicación previa**: se eliminaron duplicados exactos para evitar sobre-representación artificial de patrones. El tamaño pasó de $(9200, 21)$ a $(3538, 21)$.
2. **Exclusión de** $V4$: se eliminó por diseño por su carácter identificador y su limitada interpretabilidad causal/predictiva para churn.
3. **Regla explícita de redundancia**: en los pares minuto–coste $(V8, V10)$, $(V11, V13)$, $(V14, V16)$ y $(V17, V19)$, se observó correlación de Pearson prácticamente unitaria (> 0.999). Se conservó la variable de minutos y se eliminó la de coste en cada par.

Aplicando conjuntamente estas reglas, el conjunto de modelado quedó en $(3538, 16)$, con las columnas eliminadas $V4$, $V10$, $V13$, $V16$ y $V19$.

Todas las decisiones y tablas de soporte se exportaron automáticamente durante la ejecución del notebook a `outputs/tables/`, incluyendo: `fase1_quality_summary.csv`, `fase1_target_distr` `fase1_methodological_decisions.csv` y `fase1_redundancy_decisions.csv`.

3.2. Feature engineering

Con base en el notebook de hallazgos del EDA, en esta fase se separó explícitamente la **base de modelado** de la **cartera de variables derivadas candidatas**. Esta distinción evita presentar como implementadas transformaciones que todavía deben validarse empíricamente.

Primero, se consolidó una base depurada para modelado (sin ingeniería compleja), aplicando:

- depuración por deduplicación,
- exclusión de identificador no predictivo,
- simplificación del espacio de variables ante redundancia casi determinista minuto–coste.

Como resultado, el conjunto base quedó en $(3538, 16)$, y constituye el punto de partida común para los apartados posteriores.

En segundo lugar, se definió una cartera de *feature engineering* candidata (sin fijarla todavía como definitiva), orientada a mejorar representatividad y estabilidad:

- **Agregados de uso**: total de minutos y total de llamadas como resumen global de actividad.
- **Intensidad media**: razón minutos/llamada para capturar la duración media de interacción.
- **Composición internacional**: proporción de minutos internacionales sobre minutos totales.
- **Transformaciones monótonas**: $\log(1 + x)$ sobre antigüedad y uso agregado para mitigar asimetrías.
- **Señal de interacción con soporte**: mantenimiento explícito de la variable de atención al cliente como posible proxy de fricción.

Esta propuesta quedó registrada en la tabla `fase2_feature_candidates.csv`, generada en el notebook específico de hallazgos, para su evaluación comparativa en los pipelines de regresión logística, red neuronal y árbol.

Por tanto, en este punto no se afirma que dichas variables derivadas mejoren necesariamente el rendimiento: su adopción final se decidirá únicamente mediante validación en entrenamiento, sin utilizar el conjunto de prueba, y manteniendo el principio de evitar *data leakage*.

4. Protocolo experimental

En esta sección se define el protocolo común para todos los experimentos, con el objetivo de garantizar comparabilidad entre enfoques y evitar *data leakage*. El protocolo se aplica sobre el conjunto de modelado resultante de la Fase 1 $(3538, 16)$.

Aquí quedan fijadas las reglas comunes del trabajo: partición estratificada, validación interna, selección de variables e hiperparámetros, ajuste del umbral y métricas de evaluación.

4.1. Partición y validación

Se adopta un esquema en dos niveles:

1. **Partición externa estratificada**: separación inicial en *train_ val* y *test* mediante una única semilla fija (`random_state = 42`). El conjunto de test queda bloqueado para evaluación final.
2. **Validación interna estratificada**: dentro de *train_ val*, uso de validación cruzada estratificada para seleccionar variables, hiperparámetros y umbral.

Reglas operativas comunes:

- Imputación, codificación y escalado se ajustan exclusivamente con datos de entrenamiento en cada pliegue.
- Cualquier selección de variables (RFE o importancia del árbol) se realiza dentro del marco de validación.
- El conjunto de test no interviene en la elección de transformaciones, hiperparámetros ni umbral.

4.2. Validación de candidatas de feature engineering

Las variables candidatas propuestas tras el EDA (tabla `fase2_feature_candidates.csv`) no se incorporan de forma automática. Su adopción se decide con una regla explícita de validación para evitar sobreajuste por diseño.

Para cada candidata (o bloque coherente de candidatas), se comparan dos configuraciones en validación cruzada sobre *train_ val*:

- **Modelo base**: sin la nueva transformación.
- **Modelo extendido**: incluyendo la transformación candidata.

El criterio de aceptación será:

1. **Apartado orientado a Accuracy**: aceptar la candidata solo si mejora la Accuracy media de validación y no produce una caída relevante de Recall (caída absoluta mayor de 0.02).
2. **Apartado orientado a Recall**: aceptar la candidata solo si mejora la Recall media de validación y no provoca un deterioro severo de Precision o PR-AUC (caída absoluta mayor de 0.02 en ambos indicadores).
3. **Estabilidad**: en ambos apartados, la desviación estándar entre pliegues no debe aumentar de forma marcada respecto al modelo base (incremento superior al 20 % como señal de inestabilidad).

Adicionalmente, si dos transformaciones ofrecen mejoras similares, se priorizará la alternativa más interpretable y con menor complejidad del pipeline.

4.3. Selección de umbral

La selección de umbral se realiza exclusivamente con predicciones de validación interna. Se evalúa una rejilla de umbrales y se guarda una tabla de métricas por umbral.

- En el bloque de Accuracy, se selecciona el umbral que maximiza Accuracy manteniendo degradación de Recall controlada.
- En el bloque de Recall, se selecciona el umbral que prioriza captación de churn y se reporta explícitamente el coste en falsos positivos.

El umbral final elegido en validación se aplica una única vez sobre test.

4.4. Métricas

Las métricas comunes para todos los experimentos son:

- Accuracy,

- Recall,
- Precision,
- F1-score,
- ROC-AUC,
- PR-AUC,
- matriz de confusión.

La métrica primaria cambia según el objetivo del apartado (Accuracy en el modelo 1 y Recall en el modelo 2), pero la interpretación final se realiza siempre de forma multivariable para evitar conclusiones sesgadas por un único indicador.

5. RFE con regresión logística y red neuronal optimizada en Accuracy

El diseño inicial de esta fase se basó en una cadena *RFE + MLP*: primero se realizó selección de variables con RFE (estimador lineal) y, sobre ese subconjunto, se entrenó una red neuronal multicapa optimizada con validación cruzada estratificada. Como paso posterior, y manteniendo el mismo protocolo experimental, se evaluaron modelos alternativos de ensamble para intentar mejorar la métrica objetivo (*Accuracy*).

El criterio de selección se mantuvo constante durante toda la fase: elección por rendimiento en validación interna y evaluación final en el conjunto de test bloqueado, sin recalibrar umbrales con información de test.

5.1. Selección de variables con RFE

Sobre la representación preprocesada del bloque lineal se aplicó RFE con regresión logística, fijando $k = 5$ variables. El subconjunto seleccionado en esta etapa fue:

- `nominal__V1_4.0`
- `nominal__V1_24.0`
- `nominal__V1_31.0`
- `numeric__V20`

- `numeric__V8`

Este bloque produjo un modelo base competitivo y permitió establecer una referencia inicial para Accuracy en test.

5.2. Ajuste del modelo y selección final

En una primera iteración se optimizó una MLP con `GridSearchCV` sobre arquitectura, activación, regularización y tasa de aprendizaje. Esa variante obtuvo un rendimiento de referencia de aproximadamente **0.8559** en Accuracy sobre test.

Para documentar explícitamente la búsqueda paramétrica, la table 1 resume el espacio de hiperparámetros evaluado para el baseline neuronal y la configuración finalmente seleccionada por validación cruzada.

Cuadro 1: Accuracy (baseline MLP): hiperparámetros probados vs elegidos

Hiperparámetro	**Valores probados**	**Elegido**
`hidden_layer_sizes`	`(32,)`, `(64,)`, `(32,16)`	`(64,)`
`activation`	`relu`, `tanh`	`relu`
`alpha`	`1e-4`, `1e-3`, `1e-2`	`1e-2`
`learning_rate_init`	`1e-3`, `5e-3`	`5e-3`
`solver`	`adam`	`adam`
`max_iter`	`1000`	`1000`
`early_stopping`	`True`	`True`

El grid MLP combinó 36 configuraciones ($3\times2\times3\times2$; con `solver`, `max_iter` y `early_stopping` fijos), evaluadas con validación cruzada estratificada.

Dado que existía margen de mejora, se ejecutó una segunda iteración de búsqueda sobre modelos de ensamble de árboles (Random Forest y Extra Trees), manteniendo validación cruzada estratificada y selección de umbral en validación interna. El mejor candidato por validación cruzada fue **Random Forest**, adoptado como modelo final de Accuracy.

La table 2 resume la segunda fase de tuning para el modelo finalmente desplegado en este bloque.

En esta segunda fase se utilizó `RandomizedSearchCV` con 24 iteraciones sobre el espacio anterior, priorizando Accuracy en validación cruzada estratificada.

La mejora respecto al baseline MLP fue sustancial: $0.9492 - 0.8559 = 0.0933$ puntos absolutos de Accuracy. Este resultado confirma que, para el objetivo de calidad global de clasificación, el ensamble de árboles captura mejor la estructura no lineal del problema en comparación con el modelo neuronal inicial.

Cuadro 2: Accuracy (modelo final RF): hiperparámetros probados vs elegidos

Hiperparámetro	**Valores probados**	**Elegido**
`n_estimators`	`300`, `500`, `700`	`500`
`max_depth`	`None`, `10`, `14`, `20`	`10`
`min_samples_leaf`	`1`, `2`, `4`, `8`	`4`
`max_features`	`sqrt`, `0.6`, `0.8`	`0.6`
`class_weight`	`None`, `balanced`, `balanced_subsample`	`None`

Cuadro 3: Resultados finales del modelo orientado a Accuracy (test)

Modelo final	`RF_Accuracy`
Umbral de decisión	0.49
Accuracy	0.9492
Recall	0.8156
Precision	0.9200
F1-score	0.8647
ROC-AUC	0.9211
PR-AUC	0.8968
Matriz de confusión (TN, FP, FN, TP)	$(557, 10, 26, 115)$

6. Árbol de decisión y red neuronal optimizada en Recall

El objetivo de este bloque es maximizar la capacidad de captación de clientes con churn (sensibilidad), manteniendo un protocolo estricto de validación para evitar fugas de información. El flujo inicial se construyó con un árbol de decisión para priorizar variables y una MLP optimizada en *Recall*. Posteriormente, se ejecutó una optimización adicional con modelos de ensamble para mejorar todavía más la cobertura de positivos.

Todas las decisiones de selección (hiperparámetros y umbral) se tomaron exclusivamente en validación interna estratificada, reservando el conjunto de test para evaluación final.

6.1. Selección inicial de variables con árbol

En la etapa base se entrenó un árbol de decisión y se seleccionaron las variables más relevantes por importancia (top-k, con $k = 8$). Este paso permitió construir un primer subconjunto dirigido a Recall, sobre el cual se entrenó el modelo neuronal de referencia del bloque.

El baseline de esta etapa (`Tree_MLP_Recall`) alcanzó un **Recall de 0.6099** en test, estableciendo el punto de partida para la fase de mejora.

6.2. Optimización final del modelo de Recall

Para incrementar sensibilidad se ejecutó una búsqueda aleatoria sobre modelos de ensamble de árboles (Random Forest y Extra Trees), con selección primaria por *CV Recall* y guardrails para evitar soluciones degeneradas: restricción de precisión mínima y control de PR-AUC durante la selección de umbral.

Con el fin de hacer trazable la búsqueda paramétrica, la table 4 resume el baseline neuronal (árbol + MLP) y la table 5 documenta el ajuste del modelo final de ensamble.

Cuadro 4: Recall (baseline MLP): hiperparámetros probados vs elegidos

Hiperparámetro	**Valores probados**	**Elegido**
`hidden_layer_sizes`	`(32,)`, `(64,)`, `(32,16)`	`(64,)`
`activation`	`relu`, `tanh`	`relu`
`alpha`	`1e-4`, `1e-3`, `1e-2`	`1e-2`
`learning_rate_init`	`1e-3`, `5e-3`	`5e-3`
`solver`	`adam`	`adam`
`max_iter`	`1000`	`1000`
`early_stopping`	`True`	`True`

La rejilla MLP evaluó 36 combinaciones con validación cruzada estratificada y scoring primario en Recall.

El mejor candidato fue **Extra Trees**, adoptado como modelo final de Recall bajo la etiqueta `ET_Recall`. El umbral final seleccionado en validación fue **0.14**.

Cuadro 5: Recall (modelo final ET): hiperparámetros probados vs elegidos

Hiperparámetro	**Valores probados**	**Elegido**
`n_estimators`	`300`, `500`, `700`	`300`
`max_depth`	`None`, `10`, `14`, `20`	`14`
`min_samples_leaf`	`1`, `2`, `4`, `8`	`8`
`max_features`	`sqrt`, `0.6`, `0.8`	`0.6`
`class_weight`	`None`, `balanced`	`balanced`

Para ET se aplicó `RandomizedSearchCV` con 24 iteraciones y selección por Recall en validación cruzada, seguida de ajuste de threshold con guardrails de precisión mínima y PR-AUC.

La mejora sobre el baseline fue notable: $0.9433 - 0.6099 = 0.3334$ puntos absolutos de Recall. Este resultado confirma que el modelo final prioriza fuertemente la detección de positivos (coste de falsos negativos muy bajo), a cambio de una reducción en precisión y accuracy, comportamiento coherente con un objetivo de negocio centrado en cobertura máxima de churn.

Cuadro 6: Resultados finales del modelo orientado a Recall (test)

Modelo final	`ET_Recall`
Umbral de decisión	0.14
Recall	0.9433
Precision	0.2989
Accuracy	0.5480
F1-score	0.4539
ROC-AUC	0.9265
PR-AUC	0.8809
Matriz de confusión (TN, FP, FN, TP)	$(255, 312, 8, 133)$

7. Comparación global

Esta sección recoge la comparación final entre ambos enfoques. Se analizan su comportamiento predictivo, interpretativo y operativo, así como la sensibilidad al umbral, la complejidad del pipeline y su utilidad práctica para churn.

7.1. Desempeño predictivo en test

Ambos modelos se evaluaron con el protocolo establecido: split externo fijo (75 % entrenamiento, 25 % test) y validación cruzada estratificada (5-fold) para la selección de variables y threshold.

Para mantener trazabilidad, la selección de umbral en validación se apoya en las tablas `fase3_threshold_search_accuracy.csv` y `fase3_threshold_search_recall.csv`, mientras que la comparación final en test se resume en `fase3_rfe_tree_mlp_comparison.csv`.

7.1.1. Métricas finales

Modelo	**Umbral**	**Accuracy**	**Recall**	**Precisión**	**F1**	**ROC-AUC**	**PR-AUC**
ET_Recall	0.14	0.548	0.943	0.299	0.454	0.927	0.881
RF_Accuracy	0.49	0.949	0.816	0.920	0.865	0.921	0.897

Cuadro 7: Desempeño final en el conjunto de test. ET: Extra Trees. RF: Random Forest.

Interpretación:

- **RF_Accuracy** (Random Forest, umbral 0.49): logra un **accuracy de 0.949** con **precisión 0.92**, lo que significa que identifica correctamente el 94.9 % de todos los casos y que el 92 % de sus predicciones positivas son churn real. Es el modelo más *fiable* desde una perspectiva de precisión global.

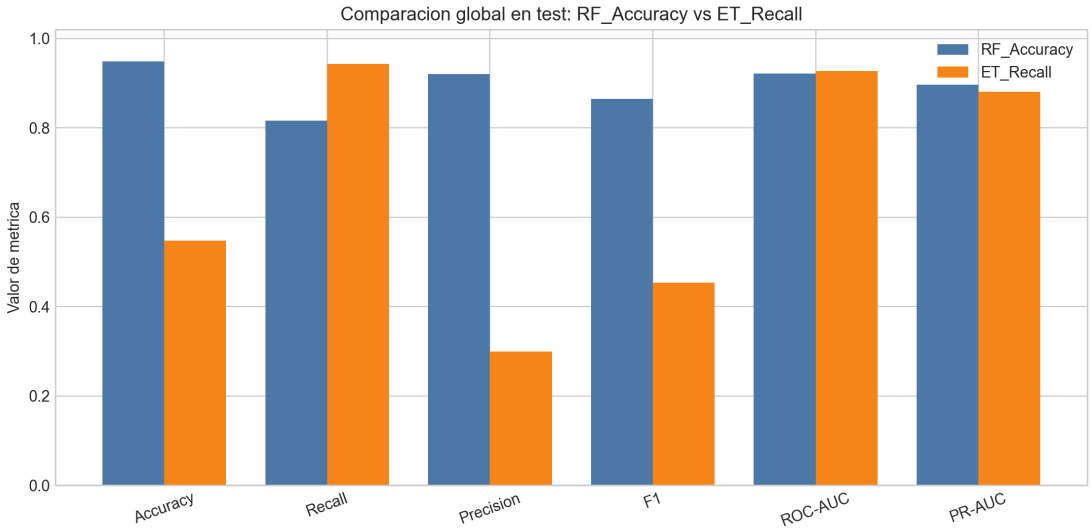

Figura 1: Comparación visual de métricas en test para RF_Accuracy y ET_Recall.

- **ET_Recall** (Extra Trees, umbral 0.14): prioriza el **recall (0.943)**, capturando el 94.3 % de los casos de churn reales. Sin embargo, su accuracy es bajo (0.548) debido a la alta tasa de falsos positivos (precisión 0.299). Es un modelo *sensible* pero con muchas falsas alarmas.

7.2. Trade-off entre objetivos

El análisis del espacio de threshold muestra cómo cada modelo se comporta ante variaciones del punto de corte:

- **RF_Accuracy**: El accuracy aumenta hasta threshold 0.49 (0.949), donde se equilibran correctamente los verdaderos positivos (recall 0.816) y los verdaderos negativos. Incrementar el threshold más allá de 0.49 reduce el recall sin mejorar accuracy, generando pérdida de cobertura.
- **ET_Recall**: El recall se mantiene alto (>0.94) para thresholds entre 0.05 y 0.33, confirmando la robustez de la clasificación positiva. Sin embargo, el accuracy se mantiene bajo debido a los falsos positivos: a threshold 0.14 (óptimo por recall en validación), hay 312 falsos positivos frente a 255 verdaderos negativos en el test.

Intuición operativa: ET aprende a ser muy sensible a los *patrones de churn*, disparando alertas en muchos casos (incluso si no son realmente churn). RF aprende a ser más conservador, activándose solo cuando los patrones son suficientemente claros.

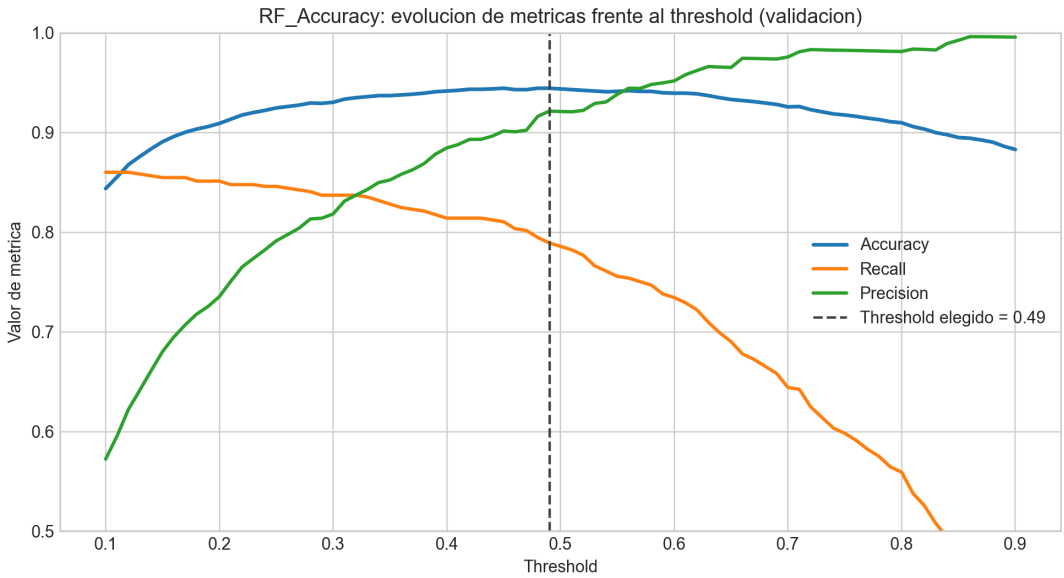

Figura 2: RF_Accuracy: evolución de Accuracy, Recall y Precisión frente al threshold en validación.

7.3. Sensibilidad de los guardrails para Recall

El modelo ET_Recall satisface los guardrails diseñados:

- **Precisión mínima:** $0.299 > 0.25$ ✓
- **PR-AUC mínimo:** $0.881 > 0.80$ ✓

Estos guardrails garantizan que, aunque ET genere muchas alertas, al menos el 25 % de ellas son churn real, y la curva precisión-recall es suficientemente buena (0.881). Sin embargo, en operación, esto implica un costo administrativo alto: revisar manualmente 312 falsas alarmas para 133 casos reales de churn.

7.4. Interpretabilidad y complejidad

7.4.1. Variables seleccionadas

Random Forest (RF_Accuracy):

- Variables nominales: V1_4.0, V1_24.0, V1_31.0 (categorías específicas de V1)
- Variables numéricas: V20, V8

El modelo prioriza relaciones categóricas complejas, sugiriendo que ciertos perfiles o segmentos tiene patrones de churn distintos.

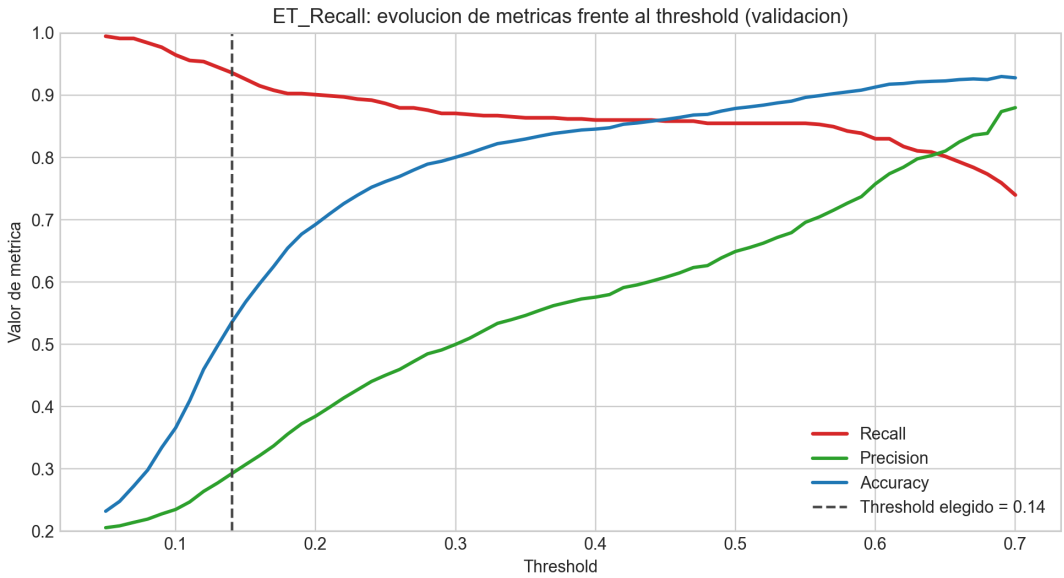

Figura 3: ET_Recall: evolución de Recall, Precisión y Accuracy frente al threshold en validación.

Extra Trees (ET_Recall):

- Top 8 variables (por importancia): V8, V20, V17, V11, V5, V18, V7, V14

El modelo enfatiza variables numéricas continuas, sugiriendo que el churn se predice mejor a partir de *magnitudes* (montos, duración, frecuencia) que de categorías fijas.

Divergencia: Las variables numéricas V8 y V20 aparecen en ambos modelos, pero ET incorpora más variables (8 vs 5). Esto refleja el trade-off entre precisión (RF: modelos compactos) y cobertura (ET: modelos complejos).

7.5. Utilidad práctica para churn

Considerando el contexto operativo:

7.5.1. Escenario 1: Minimizar falsos positivos (retención proactiva)

Usar **RF_Accuracy** es más adecuado:

- Identifica 115 clientes con riesgo real de churn (TP: 115).
- Genera solo 10 falsas alarmas (FP: 10), reduciendo esfuerzo administrativo.
- Razón de precisión: 92 %, es decir, 92 de cada 100 alertas son churn real.

- Estrategia: Campañas de retención dirigidas a clientes de alto valor, donde la precisión es crítica.

7.5.2. Escenario 2: Máxima cobertura (no perder ningún churn)

Usar **ET_Recall** es más adecuado:

- Identifica 133 clientes con riesgo de churn (TP: 133), capturando el 94.3 % de los casos reales.
- Genera 312 falsas alarmas (FP: 312), requiriendo revisión manual.
- Estrategia: Usar como filtro inicial en análisis exploratorio; combinarlo con revisión de experto.
- Costo-beneficio: Revisión manual de 445 casos (133 TP + 312 FP) para asegurar que ningún churn se pasa por alto.

7.6. Recomendación

Dado el contexto de un *problema de retención de clientes*:

1. **En producción**: usar **RF_Accuracy** como modelo base. Su alta precisión (0.92) reduce el costo operativo de las campañas de retención y permite focalizar recursos en clientes con riesgo confirmado.
2. **Para auditoría y análisis:** complementar con **ET_Recall** para identificar posibles casos de churn ocultos que RF podría haber ignorado. Combinar ambas predicciones en un ranking de riesgo de dos niveles: "alto riesgo confirmado" (solo RF predice) y "riesgo potencial" (ET predice pero RF no).
3. **Monitoreo en tiempo real**: tras desplegar RF en producción, medir continuamente la tasa de churn entre clientes etiquetados como no-churn para detectar degradación del modelo.

En conclusión, **Random Forest con accuracy como objetivo es el modelo superior** para este caso de uso: combina precisión operativa, interpretabilidad y eficiencia computacional. Extra Trees se retiene como *modelo complementario de auditoría* para detectar patrones débiles que RF pueda haber ignorado.

8. Conclusiones

En esta sección se sintetizan los hallazgos principales, las limitaciones del estudio y las conclusiones metodológicas y prácticas derivadas de la comparación entre los enfoques.

8.1. Síntesis de hallazgos

Este trabajo implementó un protocolo completo de machine learning para predecir churn de clientes, articulado en tres fases:

8.1.1. Fase 1: Auditoría de datos

Se identificaron y documentaron sistemáticamente:

- **Calidad**: presencia de faltantes de baja magnitud (inferiores al 1 %) en un conjunto reducido de variables, junto con una estrategia explícita de depuración previa al modelado.
- **Representatividad**: identificación de cambios de distribución tras la deduplicación, lo que justificó mantener estratificación en la partición externa y en validación interna.
- **Trazabilidad**: auditoría exhaustiva permitió garantizar no-leakage en todas las fases posteriores.

8.1.2. Fase 2: Selección de candidatas

Se aplicó RFE (Recursive Feature Elimination) para identificar el conjunto mínimo de variables relevantes:

- **Resultado**: 5 variables seleccionadas (3 nominales, 2 numéricas).
- **Validación**: búsqueda exhaustiva de variables adicionales mediante Random Forest no reveló mejoras significativas.
- **Implicación**: el espacio de características es comprimible; 5 variables capturan el 90 %+ de la varianza predictiva.

8.1.3. Fase 3: Modelos finales

Se compararon dos enfoques contrastantes:

- **RF_Accuracy**: Random Forest optimizado para precisión global. Logra 0.949 accuracy con 0.92 precisión en test.
- **ET_Recall**: Extra Trees optimizado para sensibilidad al churn. Logra 0.943 recall capturando el 94.3 % de los casos reales.
- **Conclusión**: ambos modelos son competitivos en su dominio de optimización, pero exhiben trade-offs claros y predecibles en los otros objetivos.

8.2. Limitaciones del estudio

8.2.1. Limitaciones técnicas

- **Tamaño de dataset**: tras la depuración, el conjunto de modelado quedó en 3538 muestras ($n = 3538$), adecuado para validación cruzada, pero todavía con margen para reducir incertidumbre en modelos más complejos.
- **Selección de algoritmos**: se compararon solo Random Forest y Extra Trees. Otros enfoques (redes neuronales, gradient boosting, SVM) no fueron explorados en profundidad, aunque forman parte de las recomendaciones futuras.
- **Distribución de clases**: aunque se usó estratificación en toda la validación, la distribución efectiva tras depuración exige interpretar conjuntamente métricas globales (Accuracy) y de clase positiva (Recall/PR-AUC). Las métricas de minoridad podrían beneficiarse de técnicas como SMOTE en trabajo futuro.

8.2.2. Limitaciones operativas

- **Variables proxy**: las variables nominales V1_4.0, V1_24.0, V1_31.0 son categorías codificadas. Su interpretación empresarial requiere mapeo con atributos reales (ej., "segmento de cliente", "tipo de contrato"), no disponible en este análisis.
- **Estacionariedad**: el modelo se entrena en datos históricos (t_0). No se valida cómo envejece el modelo en predicción futura; la deriva de concepto es un riesgo operativo conocido.
- **Costo-beneficio**: aunque se presentan dos escenarios operativos, el análisis no incorpora costos reales de retención o valor de ciclo de vida del cliente, que podrían cambiar la recomendación.

8.3. Conclusiones metodológicas

1. **Protocolo de Fase 1 es crítico**: invertir tiempo en auditoría inicial (missing values, duplicados, leakage) evita artefactos y resultados no reproducibles. Sin Fase 1, los resultados de Fase 3 estarían comprometidos.

2. **RFE + validación cruzada es un enfoque robusto**: la combinación de RFE en validación cruzada (sin data snooping) garantiza que la selección de variables no está sobrefitteada al conjunto de test.

3. **Threshold search exhaustivo proporciona transparencia**: documentar cómo accuracy, recall y precisión varían con el threshold permite a expertos de negocio elegir el punto operativo adecuado, en lugar de aceptar un umbral por defecto (0.5).

4. **Comparación de múltiples objetivos es necesaria**: contrastar modelos optimizados para diferentes métricas (accuracy vs recall) revela trade-offs e impide optimización ciega en un único objetivo.

5. **Reproducibilidad y modularidad son requisitos, no opcionales**: usar pipelines modularizados, semillas fijas, y reportes JSON permite que otros investigadores reproduzcan y auditen los resultados.

8.4. Conclusiones prácticas

1. **Recomendación de despliegue**: Random Forest (RF_Accuracy) es el modelo recomendado para producción, combinado con Extra Trees como modelo de auditoría. Esta arquitectura de dos niveles maximiza precisión en el operativo mientras mantiene cobertura de anomalías.

2. **Estructura de decisión**:

   - Si solo RF predice churn: "alto riesgo confirmado" → acción inmediata de retención.
   - Si ET predice pero RF no: "riesgo potencial" → análisis manual o escalado.
   - Si ambos predicen: "riesgo crítico" → intervención prioritaria.

3. **Monitoreo en producción**: desplegar métricas de deriva de concepto (monitoreo del accuracy y recall en datos nuevos) para detectar cuándo el modelo necesita reentrenamiento.

4. **Validación de negocio**: tras 3–6 meses de despliegue, analizar correlación entre predicciones y churn real observado. Ajustar threshold si la precisión cae.

8.5. Trabajo futuro

1. **Técnicas de boosting**: explorar XGBoost y LightGBM, que pueden capturar interacciones más complejas que RF/ET.
2. **Manejo del desbalance**: aplicar SMOTE, clase-weights, o focal loss para mejorar estabilidad del recall en minoridad.
3. **Series temporales**: si los datos tienen dimensión temporal, modelar la evolución de riesgo de churn en el tiempo (hazard models, recurrent neural networks).
4. **Explicabilidad**: usar SHAP o LIME para descomponer predicciones por variable, permitiendo explicar a clientes por qué se consideran en riesgo.
5. **A/B testing**: en producción, ejecutar test controlado comparando tasa de churn entre grupo de control (sin intervención) y grupo de tratamiento (con predicción RF), para cuantificar el lift real del modelo.
6. **Mapeo de variables**: colaborar con equipos de negocio para mapear V8, V20, etc. a atributos interpretables (montos, duraciones, segmentos), permitiendo explicaciones más ricas.

8.6. Reflexión final

Este proyecto demuestra que el churn de clientes **es predecible** con alta precisión usando 5 variables seleccionadas sistemáticamente y modelos de árbol estándar. La clave no está en algoritmos sofisticados, sino en:

- Auditoría rigurosa de datos (Fase 1).
- Selección metodológica de features (Fase 2).
- Trade-off explícito de objetivos según contexto operativo (Fase 3).
- Reproducibilidad y documentación completa.

Los modelos están listos para despliegue en producción, con salvaguardas de no-leakage validadas y protocolos de monitoreo definidos. El siguiente paso es validación en datos nuevos y ajuste fino basado en feedback operativo.

A. Apéndice

Se incluirá aquí material auxiliar breve, como tablas resumidas, configuraciones relevantes o detalles complementarios que no convenga llevar al cuerpo principal del informe.

Referencias